SK 네트웍스 Family AI 33기 : 5팀

수집 데이터 보고서

산출물 단계	데이터 수집 및 저장
제출 일자	_____
깃허브 경로	https://github.com/20260528-skn-family-ai-33/SKN33-Final-5Team
작성 팀원	김문규

수집 데이터

1. 수집 데이터 개요

- A4B 워크플로우 생성에 활용할 n8n 공개 템플릿과 WorkflowBench를 수집하고, 출처·버전·구조·수량을 점검하였다.

데이터명	수집 대상	수집 목적	사용 예정 기능	출처 / 저작권
n8n 워크플로우	템플릿 설명 및 Workflow JSON	표 처리·노드 구성 사례 확보	초안 설계, 도구 선택	Hugging Face mbakgun / MIT
WorkflowBench	Shortcuts 기반·생성 요청 및 코드	조건 분기·다단계 연결 사례 확보	초안 설계, 실행 코드	Hugging Face openbmb / 라이선스는 4절 참조

2. 수집 방법 및 자동화 절차

2.1 수집 방식 (해당 항목에 체크)

수집 방식	선택	수집 방식	선택
웹 크롤링	☐	API 호출	☑
사용자 입력	☐	문서 파일 업로드 (PDF, CSV 등)	☐
기타: 공개 파일 다운로드	☑		

2.2 수집 도구 및 자동화

사용 언어 / 라이브러리	**Python 표준 라이브러리: urllib.request, json, hashlib, zipfile, pathlib, datetime**
자동화 여부 및 주기	**스크립트 일괄 수집. 2026.10.13 최초 수집 및 재검사. 재실행 시 동일 SHA256 파일 재사용.**
오류 발생 시 예외 처리 전략	**파일별 오류 기록 후 다음 항목 처리. .part 임시 저장 후 해시 검증. 변경 원본은 버전별 보존. ZIP 경로와 해제 크기 검사.**

2.3 수집 흐름도

API 조회·버전 확인 → 파일 다운로드·SHA256 검증 → ZIP 안전 해제
→ JSON·JSONL 파싱·필드 점검 → 수집 시각·출처·크기·해시 기록

3. 데이터 설명 및 구성

3.1 파일 및 필드 설명

파일명 / 테이블명	필드명	데이터 타입	설명	예시
n8n train.jsonl	instruction	string	공통 생성 지침	워크플로우 생성 지침
n8n train.jsonl	input	string	템플릿 설명·설치 전제	자연어 업무 설명
n8n train.jsonl	output	string (JSON)	노드·연결·설정	nodes, connections
WorkflowBench seed / synthesized	query	string / null	업무 요청	자료 목록 조회 요청
WorkflowBench seed / synthesized	workflow_code	string	워크플로우 코드	함수 호출·조건 분기
WorkflowBench seed / synthesized	task_plan	string	단계별 작업 설명	조회 → 처리 → 저장
WorkflowBench seed / synthesized	key	string	원본 및 분할 식별 정보	synthesized_training_data
WorkflowBench synthesized	apis	list	관련 API 목록	API 이름 목록
수집 manifest	revision, sha256, bytes, checked_at_utc	string / int	버전·무결성·수집 기록	SHA256, 파일 크기

3.2 데이터 양

전체 수집 데이터 건수	**총 113,070건 = n8n 2,737건 + WorkflowBench 110,333건** **WorkflowBench: seed 14,523건 + synthesized 95,810건** **GitHub 참고 샘플 50건은 별도 관리**
추출된 고품질 데이터 건수 (필터링 후 기준)	**선별·변환 사례 136건 = n8n 97건 + WorkflowBench 39건** **원본 기준: n8n 84개, WorkflowBench 13개** **실행 코드용 산출물: 중복 정리 후 40건**

3.3 저장 위치 및 포맷

저장 경로	
저장 포맷	☑ JSON ☑ 기타: JSONL, ZIP, PKL
인코딩	☑ UTF-8 (JSON·JSONL 텍스트)

4. 법적·윤리적 검토

개인정보 포함 여부	이메일 형태의 문자열이 포함된 후보 확인
포함된 경우 필드	n8n 조건 상수의 이메일 문자열; 노드 credentials 참조
비식별화 조치 여부	☑ 기타: 이메일 리터럴 포함 후보 3건 제외
출처 및 사용권 — 공개 여부	☑ 공개 ☐ 내부사용 한정
라이선스 / 약관 검토 여부	n8n 데이터 카드: MIT 및 템플릿 제작자 권리 표기. WorkflowLLM GitHub LICENSE: Apache-2.0. 출처별 라이선스 문서와 revision 보존.
검토자	김문규
검토 일자	2026.10.10

5. 데이터 품질 및 정합성 관리 방안

중복 제거 기준	**원본 레코드, 요청, 정답의 해시로 중복 집계. WorkflowBench seed·synthesized 간 동일 요청/코드 2,380개 확인. 변환 단계에서는 작업군과 실행 코드 정답 기준으로 중복 관리.**
정합성 검증 방법	**JSON/JSONL 전수 파싱, 필드 타입·누락·빈 값, n8n 연결 참조 및 WorkflowBench AST 검사. n8n output JSON 2,737건 파싱 성공. 파일 SHA256 및 출처 revision 대조.**
Null 처리 및 결측치 전략	**원천은 그대로 보존하고 결측 상태를 별도 기록. synthesized query null 13건, seed 코드 빈 값 6건 확인. 변환 시 필수 요청·설정 결측 사례 제외 및 빈 값 정책 명시.**
표준화 전략	**UTF-8 텍스트로 관리하고 출처별 스키마 보존. A4B 변환 시 도구·필드·바인딩·출력 형식을 통일하며, 요청·코드 해시와 변환 사유를 함께 기록.**

6. 변경 이력 및 보완 내역

변경일	변경자	변경 내용	비고
2026.10.13	5팀	공개 API로 출처 버전 조회, n8n·WorkflowBench 파일 수집 및 SHA256 검증	원천 113,070건
2026.10.13	5팀	파일 재사용 검사, 필드·구조·중복 및 원천 평가 분할 점검	수집 명세 보존
2026.10.14	5팀	지원 작업 선별 및 A4B 형식 변환, 실행 검증, 역할별 통합	초안 136건 실행 코드 40건